Multiplicacao de Matrizes em Blocos com MPI e OpenBLAS

Resumo

Este trabalho compara tres implementacoes de multiplicacao de matrizes quadradas `float`: uma versao serial em blocos, uma versao distribuida com MPI sem BLAS e uma versao distribuida com MPI usando `cblas_sgemm` do OpenBLAS.

Os resultados foram coletados no Lovelace/CENAPAD. A validacao independente terminou com `validation=ok` nas tres versoes. A campanha principal tem 105 medicoes validas, correspondentes a 35 configuracoes com tres repeticoes cada. Tambem foram coletadas 51 medicoes em dois nos e nove medicoes de escalabilidade fraca.

O OpenBLAS foi executado com uma thread por processo. Para `N=6000`, bloco 128 e quatro processos, MPI + OpenBLAS apresentou tempo medio de 1.609950 s, contra 7.135342 s da versao MPI e 23.145013 s da versao serial. A campanha multinode atingiu o menor tempo de computacao da versao MPI + OpenBLAS em 48 processos, com 0.010830 s; em 96 processos o tempo subiu para 0.013609 s, indicando saturacao ou aumento do custo de comunicacao para este tamanho de problema.

Todos os valores deste relatorio foram derivados dos logs preservados em `results/raw/` e dos CSVs em `results/processed/`. Nenhum valor foi estimado para preencher uma medicao ausente.

Ambiente Experimental

Item	Configuracao observada
Cluster	Lovelace, CENAPAD/UNICAMP
Host de login	`lovelace.ada.cenapad.unicamp.br`
Nos PBS	`adano05` e `adano27`
CPU	AMD EPYC 7282 16-Core Processor
Memoria observada	62 GiB no host de login
Sistema	Linux kernel `4.18.0-553.150.1.el8_10.x86_64`
Compilador	GCC 9.4.0, modulo `gcc/9.4.0`
MPI	OpenMPI 4.1.1, modulo `openmpi/4.1.1-gcc-9.4.0`
CMake	4.3.1, modulo `cmake/4.3.1`
OpenBLAS	0.3.21, modulo `openblas/0.3.21-gcc-9.4.0`
Launcher	`/opt/pub/openmpi/4.1.1/gcc/9.4.0/bin/mpiexec`
Threads OpenBLAS	`OPENBLAS_NUM_THREADS=1`
Job multinode	`1032047.ada`, fila `paralela`
Alocacao multinode	2 nos, 128 CPUs e 128 processos MPI por no

O executavel `mpi_blas_mm` foi verificado com `ldd` e esta ligado a `libopenblas.so.0`. As evidencias completas estao em `results/environment/final-inventory/`.

Os benchmarks de um processo a quatro processos da campanha principal foram executados no host SSH, onde havia uma CPU visivel para a sessao. Portanto, essa parte mede principalmente oversubscription e nao deve ser interpretada como uma medida isolada de escalabilidade de nucleos fisicos. A campanha PBS multinode e usada para observar o comportamento com recursos alocados.

Implementacao

As tres versoes usam matrizes quadradas em armazenamento contiguo, com valores `float` gerados deterministicamente a partir de uma semente. O tamanho da matriz, o bloco e a semente sao configuraveis:

--n N --block B --seed S

• **Serial:** multiplicacao tiled sem BLAS.

• **MPI:** distribuicao das linhas de `A`, broadcast de `B`, multiplicacao

local tiled e coleta de `C`.

• **MPI + OpenBLAS:** mesma distribuicao MPI, usando `cblas_sgemm` para cada

produto local de blocos.

O tempo de computacao MPI e o maximo do tempo local entre os processos. O tempo total inclui broadcast, distribuicao, computacao, reducao, sincronizacao e coleta. A validacao ocorre depois da medicao e possui um cronometro separado.

Validacao de Corretude

A referencia usada na validacao e uma multiplicacao serial independente com ordem de loops `i-j-k`, diferente da implementacao tiled usada na computacao. Assim, a comparacao verifica tanto a distribuicao MPI quanto a implementacao por blocos e a chamada BLAS.

Comandos executados para `N=128`, bloco 32 e dois processos MPI:

./build/serial_mm --n 128 --block 32 --validate
mpiexec -np 2 ./build/mpi_mm --n 128 --block 32 --validate
OPENBLAS_NUM_THREADS=1 mpiexec -np 2 ./build/mpi_blas_mm --n 128 --block 32 --validate

Foram usadas tolerancias de `1.0e-3` para erro absoluto e `1.0e-4` para erro relativo. O resultado e aceito quando pelo menos uma das duas tolerancias e respeitada em cada elemento, criterio adequado para acumulacao em precisao simples.

Versao	Erro absoluto maximo	Erro relativo maximo	Validacao (s)	Resultado
Serial	2.86102295e-06	0.00520082	0.0026518	ok
MPI	2.86102295e-06	0.00520082	0.0026212	ok
MPI + OpenBLAS	6.67572021e-06	0.00440960	0.0027135	ok

O erro relativo maximo pode ser maior que `1.0e-4` em elementos cujo valor de referencia e pequeno, mas o erro absoluto permanece abaixo de `1.0e-3`. O tempo de validacao nao entra em `compute_seconds` nem em `total_seconds`. Os logs estao em `results/raw/correctness/independent-reference.out`.

Metodologia de Desempenho

A campanha forte usou:

• matrizes `N=2000`, `4000` e `6000`;

• blocos `64`, `128` e `256` para `N=2000`;

• bloco `128` para `N=4000` e `N=6000`, reduzindo o custo da campanha;

• versoes serial, MPI e MPI + OpenBLAS;

• `p=1, 2, 4` na campanha principal;

• tres repeticoes por configuracao;

• execucao sem `--validate`, para nao incluir validacao de matrizes grandes.

Para cada grupo foram calculados media, desvio-padrao populacional, minimo e maximo. As barras de erro dos graficos representam o desvio-padrao das tres repeticoes.

Tempo por Tamanho da Matriz

![Tempo por tamanho da matriz](../results/plots/report_01_tempo_por_tamanho.png)

Para bloco 128, as medias de `compute_seconds` da versao MPI + OpenBLAS foram:

N	Serial	MPI + OpenBLAS p=1	MPI + OpenBLAS p=2	MPI + OpenBLAS p=4
2000	0.882474	0.235511	0.117759	0.059574
4000	6.810632	1.893012	0.945933	0.472410
6000	23.145013	7.264287	3.621751	1.609950

O crescimento do tempo acompanha aproximadamente o custo cubico esperado da multiplicacao. O OpenBLAS reduz fortemente o custo constante, enquanto o MPI reduz o trabalho computacional por processo. A comunicacao passa a ser mais relevante conforme o tempo de computacao local diminui.

Influencia do Tamanho do Bloco

![Efeito do bloco](../results/plots/report_02_efeito_bloco.png)

As medias da versao MPI + OpenBLAS para `N=2000` foram:

Bloco	p=1	p=2	p=4
64	0.316600	0.159129	0.077233
128	0.235511	0.117759	0.059574
256	0.195526	0.099847	0.048887

O bloco 256 foi o mais rapido nos tres niveis de processos testados. Blocos menores aumentam a quantidade de chamadas e loops de tiles; blocos maiores reduzem essa sobrecarga neste ambiente, embora possam aumentar a pressao sobre cache em outras arquiteturas ou tamanhos de matriz. Esta conclusao e limitada ao conjunto `N=2000`, pois os blocos 64 e 256 nao foram medidos para `N=4000` e `N=6000` na campanha principal.

Speedup e Eficiencia

Ha duas referencias diferentes e elas nao devem ser misturadas:

1. **Ganho relativo a serial:** `T_serial / T_versao(p)`. Mede o ganho total de trocar a implementacao serial pela versao MPI ou MPI + OpenBLAS. 2. **Speedup paralelo:** `T_versao(1) / T_versao(p)`. Mede somente o efeito de aumentar o numero de processos dentro da mesma versao.

A eficiencia paralela e `speedup_paralelo / p`. O arquivo `speedup_efficiency.csv` preserva as duas referencias: as colunas `speedup` e `efficiency` sao relativas a serial, enquanto `parallel_speedup` e `parallel_efficiency` sao as metricas convencionais de escalabilidade da mesma versao.

![Escalabilidade forte](../results/plots/report_03_escalabilidade_forte.png)

Para `N=6000`, bloco 128 e MPI + OpenBLAS, o speedup relativo a serial foi 3.186 em p=1, 6.391 em p=2 e 14.376 em p=4. Esse ganho combina BLAS e MPI; por isso sua eficiencia relativa a serial pode ultrapassar 1 e nao deve ser chamada de eficiencia paralela. A eficiencia paralela deve ser lida no grafico acima ou nas colunas `parallel_efficiency`.

Escalabilidade Forte PBS Multinode

A campanha PBS usou `N=2000`, bloco 128, dois nos e tres repeticoes nos niveis de processos `1, 2, 4, 8, 16, 32, 48 e 96`. As medias de computacao foram:

Processos	MPI	MPI + OpenBLAS
1	0.972636	0.234000
2	0.490366	0.117708
4	0.244848	0.058498

Processos	MPI	MPI + OpenBLAS
8	0.122588	0.030240
16	0.061729	0.017037
32	0.031724	0.011754
48	0.022448	0.010830
96	0.017630	0.013609

![Campanha multinode](../results/plots/report_04_multinode.png)

MPI + OpenBLAS atingiu seu menor tempo de computacao em 48 processos. Ao passar para 96 processos, o tempo aumentou 25.7% em relacao a 48 processos. Na versao MPI sem BLAS, o tempo ainda caiu em 96 processos, mas com eficiencia paralela menor, aproximadamente 0.517. O comportamento indica que o tamanho fixo de `N=2000` deixa pouco trabalho por processo nos niveis mais altos.

O overhead medio de `total_seconds - compute_seconds` na versao MPI + OpenBLAS foi aproximadamente 0.0041 s em p=1, 0.0221 s em p=8, 0.0437 s em p=48 e 0.0680 s em p=96 na primeira repeticao documentada. Esse overhead inclui broadcast, distribuicao, sincronizacao e coleta; seu crescimento explica parte da piora em p=96.

Nao foi feita uma comparacao controlada mantendo todo o restante fixo entre um no e dois nos: a campanha principal foi executada no host SSH e a campanha multinode pelo PBS. Portanto, o resultado demonstra o comportamento observado com a alocacao multinode, mas nao deve ser apresentado como um speedup puro de numero de nos.

Escalabilidade Fraca

Foi usada a regra aproximada `N proporcional a p^(1/3)`, mantendo o trabalho computacional por processo aproximadamente constante:

Processos	N	Bloco	Versao	Media (s)	Desvio-padrao (s)
1	2000	128	MPI + OpenBLAS	0.232640	0.000139
2	2520	128	MPI + OpenBLAS	0.237548	0.000454
4	3175	128	MPI + OpenBLAS	0.240504	0.000778

![Escalabilidade fraca](../results/plots/report_05_escalabilidade_fraca.png)

O tempo aumentou apenas 3.4% entre p=1 e p=4 nas configuracoes testadas, indicando comportamento aproximadamente constante. Esta campanha foi feita em um unico host com as limitacoes de CPU visivel registradas no inventario, logo nao deve ser interpretada como uma prova de escalabilidade fraca em varios nos.

Memoria e Gargalos

Considerando tres matrizes `float` completas, o armazenamento teorico e:

N	Tres matrizes
2000	0.0447 GiB
4000	0.1788 GiB
6000	0.4023 GiB

Esses valores nao incluem buffers MPI, bibliotecas ou temporarios. Sao estimativas de armazenamento, nao medidas de RSS. A implementacao MPI replica `B` nos processos e distribui linhas de `A`, enquanto o processo raiz mantem o resultado coletado. Essa escolha simplifica a distribuicao, mas aumenta a pressao agregada de memoria conforme o numero de processos cresce.

Os principais gargalos observados sao:

• custo de broadcast e coleta, visivel na diferenca entre tempo total e tempo

de computacao;

• sincronizacao e latencia quando o trabalho por processo fica pequeno;

• chamadas e loops adicionais para blocos menores;

• saturacao ou desequilibrio em MPI + OpenBLAS acima de 48 processos para

`N=2000`;

• possivel pressao de cache para blocos muito grandes, embora 256 tenha sido o

melhor dos blocos medidos neste ambiente.

Reprodutibilidade

Os logs brutos, inventarios, CSVs e graficos estao versionados. O fluxo de processamento e:

python3 scripts/process_results.py --raw-dir results/raw/benchmark-final
python3 scripts/process_results.py --raw-dir results/raw/1032047.ada-20261019-163130-multinode --prefix multinode
python3 scripts/process_results.py --raw-dir results/raw/weak-20261019-145859 --prefix weak
python3 scripts/plot_results.py
python3 scripts/generate_report_pdf.py

O processamento produz medições individuais, estatisticas, speedup relativo à serial e speedup/eficiencia paralelos. Os scripts PBS passaram por `bash -n`. As medições da campanha multinode foram executadas com o commit `d42be2b22ad525f6064530d1c56e32dda3f42c43`, registrado no inventario final; as alterações posteriores de validacao, processamento e documentacao nao alteram os tempos coletados. Os artefatos principais sao:

• `results/environment/final-inventory/`;

• `results/raw/correctness/`;

• `results/raw/benchmark-final/`;

• `results/raw/1032047.ada-20261019-163130-multinode/`;

• `results/raw/weak-20261019-145859/`;

• `results/processed/`;

• `results/plots/`;

• `report/report.pdf`.

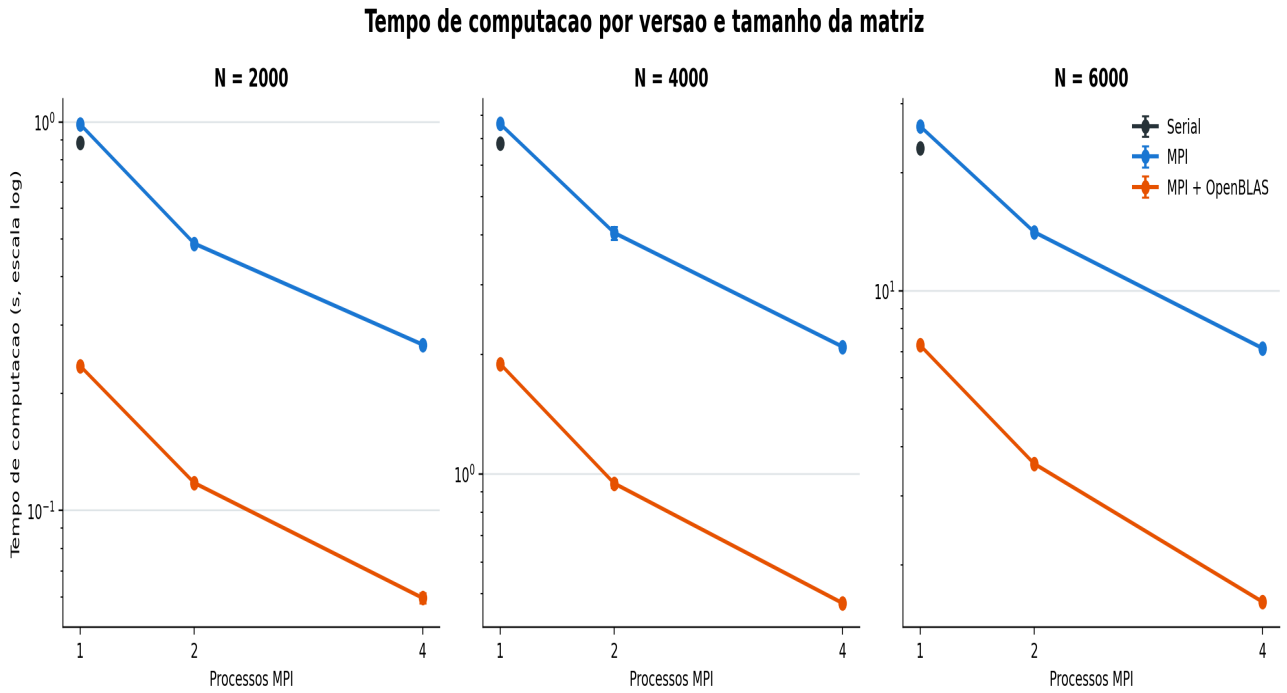
Conclusao

MPI + OpenBLAS foi a alternativa mais rapida em todas as configuracoes comparaveis. O OpenBLAS reduz substancialmente o custo da multiplicacao local, enquanto MPI distribui o trabalho entre processos. A escalabilidade e boa nos primeiros niveis de processos, mas o ganho deixa de crescer proporcionalmente quando o trabalho por processo se torna pequeno e os custos de comunicacao e saturacao dominam.

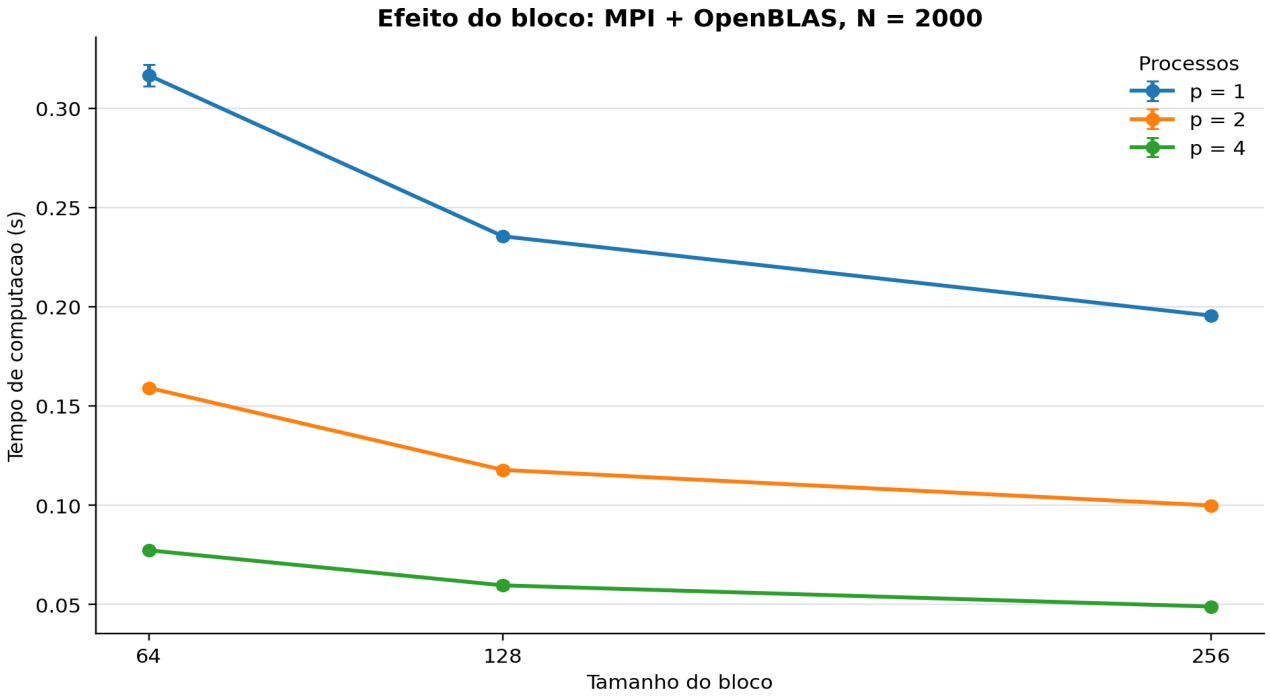
Os resultados sustentam as conclusoes para o hardware, tamanhos, blocos, numero de processos e configuracoes executados. Nao sustentam generalizacoes para outras arquiteturas, mais threads OpenBLAS, outros tamanhos de bloco ou uma comparacao pura de um no contra dois nos sem nova campanha controlada.

Graficos de desempenho

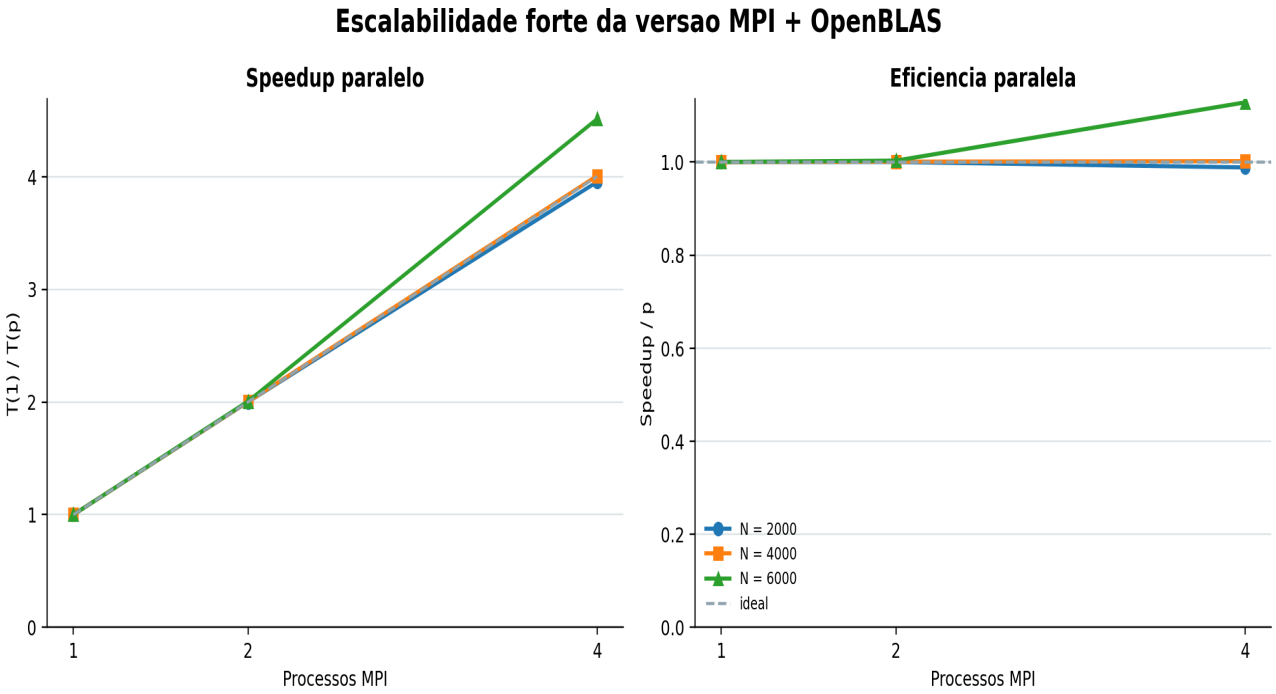
report_01_tempo_por_tamanho.png



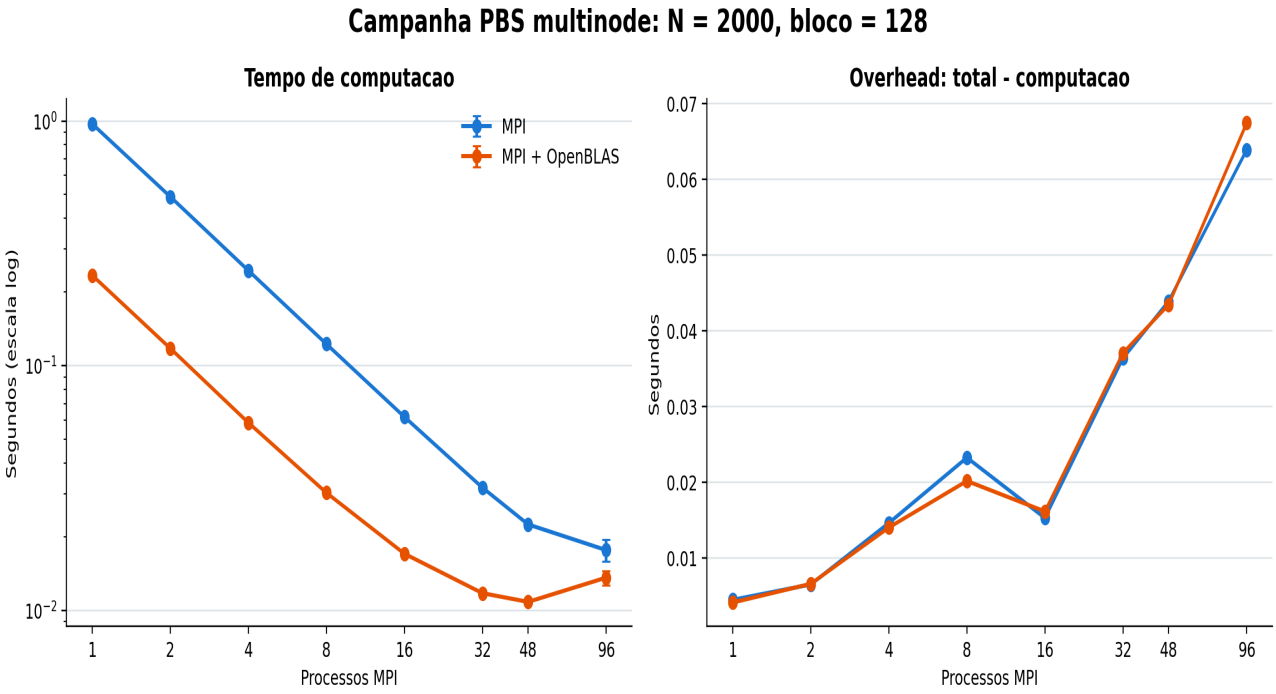
report_02_efeito_bloco.png



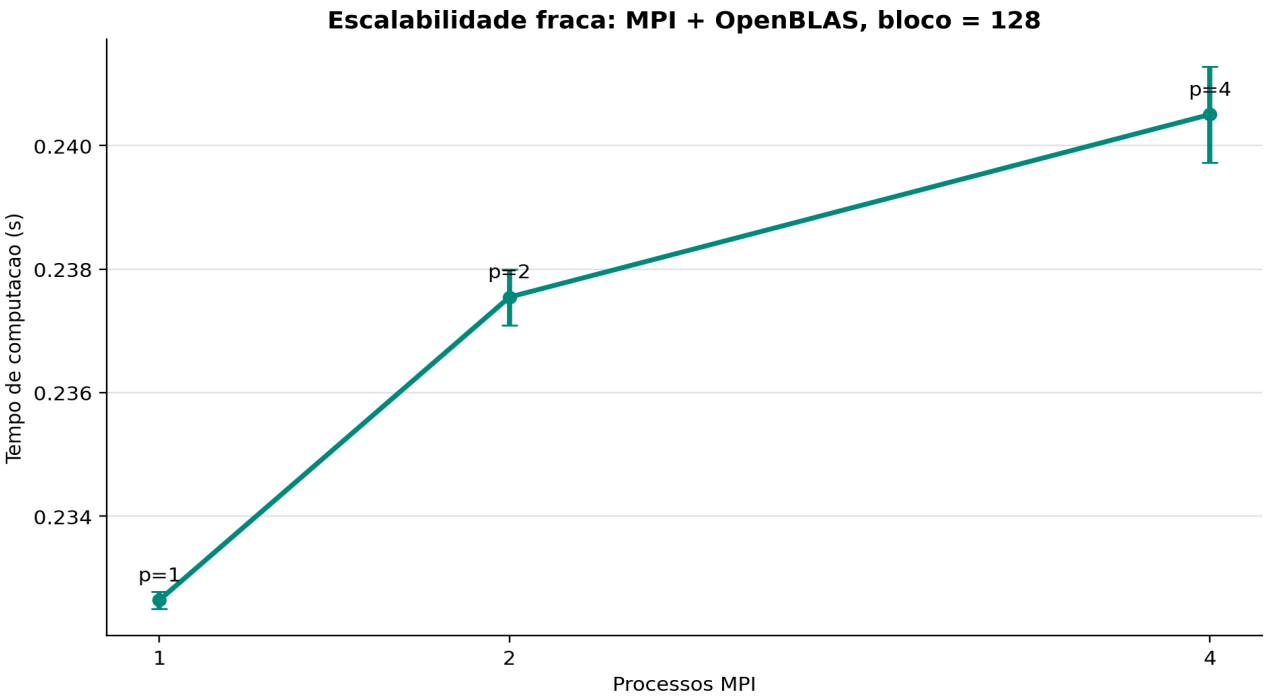
report_03_escalabilidade_forte.png



report_04_multinode.png



report_05_escalabilidade_fraca.png


Escalabilidade fraca: MPI + OpenBLAS, bloco = 128
Tempo de computacao (s)
0.240
0.238
0.236
0.234
p=1
p=2
p=4
1
2
4
Processos MPI